



# Statistik

## Konfusionsmatrix (Wiederholung)

# Konfusionsmatrix

## Beurteilung eines binären Klassifikators



- > Klassifizierung durch Klassifikator in verschiedene Klassen
  - Im Allgemeinen fehlerbehaftet
  - Klassifikation häufig binär (zwei mögliche Klassen)
  - Darstellung als Konfusionsmatrix (Wahrheitsmatrix, Verwechslungsmatrix)
    - Quadratische Tabelle mit relativen Kombinationen der Häufigkeiten von tatsächlichen (wahren) und durch Klassifikator bestimmten (vorhergesagten) Klassen
  - Erlaubt Beurteilung des Klassifikators
- Mögliche Kombinationen
  - Richtig positiv (TP)
  - Falsch negativ (FN)
  - Falsch positiv (FP)
  - Richtig negativ (TN)

| Total = P + N |              | Vorhergesagt        |                     |
|---------------|--------------|---------------------|---------------------|
|               |              | Positive (PP)       | Negative (PN)       |
| Tatsächlich   | Positive (P) | True Positive (TP)  | False Negative (FN) |
|               | Negative (N) | False Positive (FP) | True Negative (TN)  |

The background of the slide is a close-up photograph of a document. The word 'Statistik' is prominently displayed in the center, written in a bold, black, sans-serif font. It is highlighted with a thick, orange, brush-stroke-like underline. The surrounding text is blurred, showing words like 'von', 'nd', 'al-', 'tigter', 'Rolle.', 'Schaus', 'die,', 'Merkmale', and 'Wiederholung'.

Maßzahlen zur statistischen Klassifikation (Wiederholung)

# Maßzahlen zur statistischen Klassifikation

## Prävalenz, Sensitivität, Spezifität, weitere Maßzahlen

| Total = P + N |              | Vorhergesagt        |                     |
|---------------|--------------|---------------------|---------------------|
|               |              | Positive (PP)       | Negative (PN)       |
| Tatsächlich   | Positive (P) | True Positive (TP)  | False Negative (FN) |
|               | Negative (N) | False Positive (FP) | True Negative (TN)  |



- **Prävalenz**
  - Anteil an Population/Stichprobe
- Positive Vorhersage, wenn tatsächlich positiv
  - $P(\text{positive Vorhersage} | \text{tatsächlich positiv})$
  - **Sensitivität**, Hit rate, **Recall**, True Positive Rate (TPR), **Power**, **1-β**
- Positive Vorhersage wenn tatsächlich negativ
  - $P(\text{positive Vorhersage} | \text{tatsächlich negativ})$
  - False Positive Rate (FPR), **Type I error**, **α**
- Negative Vorhersage, wenn tatsächlich negativ
  - $P(\text{negative Vorhersage} | \text{tatsächlich negativ})$
  - **Spezifität**, True Negative Rate (TNR)
- Negative Vorhersage, wenn tatsächlich positiv
  - $P(\text{negative Vorhersage} | \text{tatsächlich positiv})$
  - False Negative Rate (FNR), **Type II error**, **β**

$$\text{Prävalenz} = \frac{P}{P+N} = \frac{TP+FN}{TP+FN+FP+TN}$$

$$TPR = \frac{TP}{P} = \frac{TP}{TP+FN} = 1 - FNR$$

$$FPR = \frac{FP}{N} = \frac{FP}{FP+TN} = 1 - TNR$$

$$TNR = \frac{TN}{N} = \frac{TN}{FP+TN} = 1 - FPR$$

$$FNR = \frac{FN}{P} = \frac{FN}{TP+FN} = 1 - TPR$$

# Maßzahlen zur statistischen Klassifikation

## Weitere Maßzahlen

- Verhältnis falsch-positiv und positiv vorhergesagten Ergebnissen
  - **False Discovery Rate (FDR)**
- Anteil der positiven Ergebnisse an tatsächlich positiven Ergebnissen
  - **Precision**, Positive Predictive Value (**PPV**)
- Anteil der korrekten Vorhersagen (true positive & true negative)
  - **Accuracy**
- Harmonisches Mittel von Precision und Recall
  - **F<sub>1</sub> Score**, Sørensen-Dice Koeffizient
- **Youden-Index**, Youdens J
- **Intersection-over-Union (IoU)**
  - Jaccard index, Tanimoto index
- Weitere: [https://en.wikipedia.org/wiki/Confusion\\_matrix](https://en.wikipedia.org/wiki/Confusion_matrix)

| Total = P + N |              | Vorhergesagt        |                     |
|---------------|--------------|---------------------|---------------------|
|               |              | Positive (PP)       | Negative (PN)       |
| Tatsächlich   | Positive (P) | True Positive (TP)  | False Negative (FN) |
|               | Negative (N) | False Positive (FP) | True Negative (TN)  |



$$FDR = \frac{FP}{PP} = \frac{FP}{TP+FP} = 1 - PP$$

$$PPV = \frac{TP}{PP} = \frac{TP}{TP+FP} = 1 - FDR$$

$$Accuracy = \frac{TP+TN}{P+N} = 1 - PPV$$

$$F_1 = \frac{TP}{TP + \frac{FP+FN}{2}} = 2 * \frac{PPV * TPR}{PPV + TPR}$$

$$Y = TPR + TNR - 1$$

$$IoU = \frac{TP}{TP+FP+FN}$$




**Statistik**

Anwendungsbeispiel: CNN (Wiederholung)

# Anwendungsbeispiel


## Convolutional Neural Network – Training



<https://www.youtube.com/watch?v=dgxe15vCR7s>

# Anwendungsbeispiel

## Convolutional Neural Network



- CNN zur Detektion von Katzen in Bildern
  - Ausgabe: *Catlikeism* des Bildes [0; 1]
  - *Catlikeism* < 0,8 = Keine Katze;  $\geq 0,8$  = Katze
- Test mit 1000 Bilder (500x Katze, 500x keine Katze)
  - Ground Truth (Bilder klassifiziert)


0,93: Katze



0,81: Katze



0,14: Keine Katze



Konfusionsmatrix

| 1000 = 500 + 500 |              | Vorhergesagt  |               |
|------------------|--------------|---------------|---------------|
|                  |              | Positive (PP) | Negative (PN) |
| Tatsächlich      | Positive (P) | 217 (TP)      | 283 (FN)      |
|                  | Negative (N) | 13 (FP)       | 487 (TN)      |



# Anwendungsbeispiel

## Convolutional Neural Network



- CNN für Detektion von Katzen in Bildern (Schwelle: 0,8)

- Sensitivität/Recall:  $\frac{TP}{TP+FN} = \frac{TP}{P} = \frac{217}{500} = 0,434$

(Verhältnis „Katzen korrekt vorhergesagt“ zu „tatsächlichen Katzen“)

- Spezifität:  $\frac{TN}{FP+TN} = \frac{TN}{N} = \frac{487}{500} = 0,974$

(Verhältnis „Keine-Katze korrekt vorhergesagt“ zu „tatsächlich keine Katzen“)


- Precision:  $\frac{TP}{PP} = \frac{TP}{TP+FP} = \frac{217}{217+13} = 0,943$

(Verhältnis „Katzen korrekt vorhergesagt“ zu „Katzen vorhergesagt“)

- Accuracy:  $\frac{TP+TN}{P+N} = \frac{217+487}{500+500} = 0,704$

(Verhältnis korrekte Vorhersagen zu Gesamtzahl)


| 1000 = 500 + 500 |              | Vorhergesagt  |               |
|------------------|--------------|---------------|---------------|
|                  |              | Positive (PP) | Negative (PN) |
| Tatsächlich      | Positive (P) | 217 (TP)      | 283 (FN)      |
|                  | Negative (N) | 13 (FP)       | 487 (TN)      |



# Anwendungsbeispiel

## Convolutional Neural Network – Optimierung Schwellwert

> CNN zur Detektion von Katzen in Bildern, Einfluss Schwellwert




| Threshold = 0,8 |              | Vorhergesagt  |               |
|-----------------|--------------|---------------|---------------|
|                 |              | Positive (PP) | Negative (PN) |
| Tatsächlich     | Positive (P) | 217 (TP)      | 283 (FN)      |
|                 | Negative (N) | 13 (FP)       | 487 (TN)      |

- Sensitivity = 0,434
- Specificity = 0,974
- Accuracy = 0,704

# Anwendungsbeispiel

## Convolutional Neural Network – Optimierung Schwellwert

> CNN zur Detektion von Katzen in Bildern, Einfluss Schwellwert



| Threshold = 0,5 |              | Vorhergesagt  |               |
|-----------------|--------------|---------------|---------------|
|                 |              | Positive (PP) | Negative (PN) |
| Tatsächlich     | Positive (P) | 480 (TP)      | 20 (FN)       |
|                 | Negative (N) | 96 (FP)       | 404 (TN)      |

- Sensitivity = 0,960 (0,434)
  - Specificity = 0,808 (0,974)
  - Accuracy = 0,884 (0,704)
- (Threshold = 0,8)

**Statistik**


Receiver Operating Characteristic (ROC)



# Receiver Operating Characteristic (ROC)





- Entwickelt während des 2. Weltkriegs zur Analyse der Klassifikationsgenauigkeit von Radarsignalen
  - Unterscheidung Signal / Rauschen
  - <https://mlu-explain.github.io/roc-auc/>
- Metrik zur Beurteilung der Qualität von Klassifikationsproblemen
  - Beschreibt (visuell), wie gut ein Modell zwischen Klassen unterscheiden kann
- Konstruktion
  - Bestimmung Sensitivität und Spezifität für jede Parameteränderung
  - Auftragen in Diagramm
    - Abszisse (x-Achse): 1-Spezifität (FPR)
    - Ordinate (y-Achse): Sensitivität (TPR)
- Optimum von Sensitivität und Spezifität gesucht
  - Schnittpunkt Tangente parallel zu Diagonale mit ROC Kurve
  - ➡ Youden-Index (Sensitivität + Spezifität - 1) maximal







# Receiver Operating Characteristic (ROC)

## Area Under the Curve (AUC)

- Fläche unter der ROC Kurve  $AUC \in [0; 1]$



1-Spezifität (FPR) = 1  
Sensitivität (TPR) = 1



1-Spezifität (FPR) = Sensitivität (TPR)

# Receiver Operating Characteristic (ROC)

## Optimierung des CNN Schwellwerts



- Veränderung Parameter → Bestimmung Sensitivität und Spezifität
  - Im Beispiel: Anpassung Schwellwert

- Auftragen ROC Diagramm

$$\text{Sensitivity} = \frac{TP}{TP + FN}$$

$$\text{Specificity} = \frac{TN}{FP + TN}$$

$$J = \text{Sensitivity} + \text{Specificity} - 1$$

- Bestimmung optimaler Schwellwert



- Graphisch
- Maximaler Youden's Index
  - Youden's J = 0,768 für Threshold = 0,5

- Vergrößerung Anzahl Parametertests

- Diskrete ROC → stetige ROC

- Alternative: Automatisch durch JMP

- Tabelle
- Analyse → Y nach X anpassen
  - X, Faktor: Wahrscheinlichkeit
  - Y, Zielgröße: Ground Truth
- Rotes Dreieck → ROC-Kurve





# Statistik


Wahrscheinlichkeitsintervalle und Punktschätzer (Wiederholung)

# Wahrscheinlichkeitsintervall für Punktschätzer

## Verteilung Größe Deutschland




- $Groesse \sim N(171,55; 9,55)$
- Intervall für 5% der größten Menschen



- Zufällige Auswahl 100 Personen  
~ 5 Personen  $\geq 187,26 \text{ cm}$  ( $\equiv \mu + 1,64\sigma$ )
- Wahrscheinlichkeit zufällige Wahl einer Person  $\geq 187,26 \text{ cm}$ : 5%

- Intervall, in der 95% der Menschen liegen



- Zufällige Auswahl 100 Personen  
~ 95 Personen  $\geq 152,84$  und  $\leq 190,27 \text{ cm}$   
( $\equiv [\mu - 1,96\sigma; \mu + 1,96\sigma]$ )
- Wahrscheinlichkeit zufällige Wahl einer Person  $\geq 152,84$  und  $\leq 190,27 \text{ cm}$ : 95%





## k- $\sigma$ -Bereiche, Sigma-Regeln

- > Ermittlung eines Intervalls für gegebene Wahrscheinlichkeit
  - Normalverteilte Zufallsgrößen  $X \sim N(\mu, \sigma^2)$ 
    - Symmetrisch um Erwartungswert  $\mu$
  - Intervall i.d.R. durch Vielfachens der Standardabweichung  $\sigma$  zum Erwartungswert  $\mu$ 
    - Z-Transformation (siehe frühere Folie)

$$P(|X - \mu| \leq k * \sigma) = P(\mu - k * \sigma \leq X \leq \mu + k * \sigma)$$

- > Sigma-Regeln


| Intervall I                      | $P(X \in I)$    | Intervall I                            | $P(X \in I)$   |
|----------------------------------|-----------------|----------------------------------------|----------------|
| $[\mu - \sigma; \mu + \sigma]$   | $\approx 0,683$ | $[\mu - 1,64\sigma; \mu + 1,64\sigma]$ | $\approx 0,90$ |
| $[\mu - 2\sigma; \mu + 2\sigma]$ | $\approx 0,954$ | $[\mu - 1,96\sigma; \mu + 1,96\sigma]$ | $\approx 0,95$ |
| $[\mu - 3\sigma; \mu + 3\sigma]$ | $\approx 0,997$ | $[\mu - 2,58\sigma; \mu + 2,58\sigma]$ | $\approx 0,99$ |

# Statistik

Schätzung der Wahrscheinlichkeit bei unbekannter Verteilung

# Ungleichung von Bienaymé-Tschebyscheff

- > Pafnuti Lwowitsch Tschebyschow (1821 – 1894), Mathematiker
  - Einer der bedeutendsten russischen Mathematiker des 19. Jh.
  - *Journal de Mathématiques Pures et Appliquées*, 1867
- > Irénée-Jules Bienaymé (1796 – 1878), Wahrscheinlichkeitstheoretiker, Statistiker
  - Schüler von Laplace
  - Forschung u.a. über das Aussterben geschlossener Familienkreise
  - *Considérations a l'appui de la découverte de Laplace sur la loi de probabilité dans la méthode des moindres carrés*, 1853
- > Abschätzung für maximale Wahrscheinlichkeit dass Wert einer Zufallsvariable außerhalb bestimmter Intervallgrenzen, unabhängig von (stetiger) Verteilung
  - Obere Abschätzung, Wahrscheinlichkeit kann kleiner sein
- > Abschätzung für Wahrscheinlichkeit der Abweichung einer Zufallsvariable vom Erwartungswert um mehr als gegebenen Schwellwert durch ihre Varianz



# Ungleichung von Bienaymé-Tschebyscheff

- > Für eine beliebig stetig verteilte (d.h. beliebige Verteilung) Zufallsvariable  $X$  und Wert  $k > 0$  gilt:

$$P(|X - E(X)| \geq k) \leq \frac{\text{Var}(X)}{k^2} \quad (\text{obere Grenze})$$

oder äquivalent (Gegenwahrscheinlichkeit):

$$P(|X - E(X)| < k) \geq 1 - \frac{\text{Var}(X)}{k^2} \quad (\text{untere Grenze})$$

- > Je kleiner die Varianz, desto stärker ist die Verteilung um Erwartungswert konzentriert
- > Erlaubt die Abschätzung für Wahrscheinlichkeit, dass  $X \in [E(X) - k, E(X) + k]$
- > Alternativ: Abweichung ausgedrückt durch Standardabweichung  $\sigma$  (nur sinnvoll für  $\lambda > 1$ )

$$P(|X - \mu| \geq \lambda\sigma) \leq \frac{1}{\lambda^2}$$

# Ungleichung von Bienaymé-Tschebyscheff

## Beispiel: Körpergröße

- Die durchschnittliche Körpergröße in Deutschland beträgt 171,55 cm mit einer Varianz von  $9,55^2 \text{ cm}^2$ 
  - Annahme: Verteilung unbekannt
- Wie hoch ist die Wahrscheinlichkeit für die zufällige Auswahl einer Person mit einer Größe kleiner oder größer als zwei Standardabweichung der Durchschnittsgröße?

- Tschebyscheff-Ungleichung:

$$P(|X - E(X)| \geq \lambda\sigma) \leq \frac{1}{\lambda^2}$$
$$P(|X - E(X)| \geq 2 * 9,55) \leq \frac{1}{2^2}$$

$$P(|X - E(X)| \geq 19,1) \leq 0,25$$

- Die Wahrscheinlichkeit für die zufällige Auswahl einer Person mit einer Größe kleiner oder größer als zwei Standardabweichung der Durchschnittsgröße ist höchstens 25%.



# Ungleichung von Bienaymé-Tschebyscheff

## Beispiel: Wikipedia-Artikel

- > Wikipedia-Artikel haben im Durchschnitt eine Länge von 1000 Zeichen mit einer Standardabweichung von 200 Zeichen

- $E(X) = 1000$
  - $Var(X) = 200^2$

- > Wie hoch ist die Wahrscheinlichkeit mindestens, dass ein Artikel eine Länge zwischen 600 und 1400 Zeichen hat?

$$\begin{aligned}k &= 1000 - 600 = 400 \\&= 1400 - 1000 = 400\end{aligned}$$

- > Einsetzen in Tschebyscheff-Ungleichung für untere Grenze:  $P(|X - E(X)| < k) \geq 1 - \frac{Var(X)}{k^2}$

$$P(|X - 1000| < 400) = 1 - \frac{200^2}{400^2} = 1 - 0,25 = 0,75$$

- > Die Wahrscheinlichkeit für eine Artikellänge zwischen 600 und 1400 Zeichen ist mindestens 75%

# Statistik

Warum ist die Normalverteilung normal?

# Normalverteilung als Grenzverteilung



## Konvergenz verschiedener Verteilungen gegen Normalverteilung

- Approximation verschiedener Verteilungen durch Normalverteilung
  - Binomial-Verteilung (Satz von Moivre-Laplace:  $np(1-p) > 9$ )
  - Hypergeometrische Verteilung (für sehr große  $n \rightarrow$  Binomialverteilung  $\rightarrow$  Normalverteilung)
  - Poisson-Verteilung (für große  $\lambda$ :  $\lambda > 30$ )
  - *Chi-Quadrat-Verteilung (für große  $n$ :  $n \geq 100$ )*
  - *Student t-Verteilung (für große  $n$ :  $n \geq 30$ )*
  - *Logarithmische Normalverteilung*

## Intuitive Erklärung

### Würfelspiel

- Einzelner Würfel
  - Mögliche Werte: 1 – 6
  - Jede Augenzahl gleichwahrscheinlich  
⇒ Gleichverteilung
    - Mittelwert: 3,5
    - Standardabweichung:  $\approx 1,73$
- Zwei Würfel
  - Summe der Augenzahlen  
⇒ Symmetrische Dreiecksverteilung
    - Mittelwert: 7
    - Standardabweichung  $\approx 2,45$



# Intuitive Erklärung

## Würfelspiel

- Häufigkeit für Summe 12 (2x 6 Augen): 1  
⇒ Wahrscheinlichkeit für Summe 12
  - Aus 3. abgeleiteter Regel oder 1. Pfadregel (Produktregel):  



$$P(12) = P(6 \cap 6) = P(6) * P(6) = \frac{1}{6} * \frac{1}{6} = \frac{1}{36}$$
- Häufigkeit für Summe 7: 6  
⇒ Wahrscheinlichkeit für Summe 7
  - Aus 2. Pfadregel:  

$$P(7) = P(1 \cap 6) \cup P(2 \cap 5) \cup P(3 \cap 4) \cup P(4 \cap 3) \cup P(5 \cap 2) \cup P(6 \cap 1)$$

$$= \underbrace{P(1) * P(6)}_{\text{orange}} + \underbrace{P(2) * P(5)}_{\text{blue}} + \underbrace{P(3) * P(4)}_{\text{red}} + \underbrace{P(4) * P(3)}_{\text{red}} + \underbrace{P(5) * P(2)}_{\text{blue}} + \underbrace{P(6) * P(1)}_{\text{orange}}$$


$$= \frac{2}{36} + \frac{2}{36} + \frac{2}{36}$$

$$= \frac{6}{36} = \frac{1}{6}$$
- Unwahrscheinliches Ereignis \* unwahrscheinliches Ereignis  
⇒ sehr unwahrscheinliches Ereignis
- Wahrscheinliches Ereignis \* wahrscheinliches Ereignis  
⇒ weniger wahrscheinliches Ereignis




# Intuitive Erklärung

## Würfelspiel




- Drei Würfel
  - Summe der Augenzahlen



⇒ Annäherung an Normalverteilung

- Mittelwert: 10,5
- Standardabweichung  $\approx 2,96$

- Vier Würfel
  - Summe der Augenzahlen



⇒ Annäherung an Normalverteilung

- Mittelwert: 14
- Standardabweichung  $\approx 3,42$

- Bei der Summe einer Zufallsvariable von vielen Wiederholungen (großes  $n$ ) eines Zufallsexperiments erscheint die Normalverteilungen



# Statistik

## Grenzwertsätze der Stochastik

# Gesetze der großen Zahlen

## Schwaches Gesetz der großen Zahlen



- Die Häufigkeit mit der ein Zufallsereignis eintritt, nähert sich seiner theoretischen Wahrscheinlichkeit immer weiter an, je häufiger ein Zufallsexperiment durchgeführt wird

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n (X_i - E(X)) \right| < \varepsilon \right) = 1, \text{ für alle } \varepsilon > 0$$



Jakob I Bernoulli, 1689

- Die Wahrscheinlichkeit dafür, dass die Differenz des Mittelwertes einer unendlichen Folge von Zufallsvariablen und des Erwartungswertes  $E(X)$  kleiner als eine beliebig kleine positive Zahl ist, liegt bei 100 Prozent und ist somit *stochastisch wahrscheinlich*
- Die Folge der zentrierten Mittelwerte **konvergiert in Wahrscheinlichkeit** gegen 0
- Voraussetzung:  $X_i$  paarweise unabhängig und identisch verteilt (*independent and identical distributed, iid*)

# Gesetze der großen Zahlen

## Starkes Gesetz der großen Zahlen

- Jakob Bernoulli, Émile Borel, Francesco Paolo Cantelli, Andrei Nikolajewitsch Kolmogorow, Nasrollah Etemadi

$$P\left(\lim_{n \rightarrow \infty} \bar{X}_n = E(X)\right) = 1$$


- Die Wahrscheinlichkeit dafür, dass bei einer unendlichen Folge von Zufallsvariablen der Mittelwert dem Erwartungswert  $E(X)$  entspricht, liegt bei 100 Prozent, ist also fast sicher
- Der Mittelwert der zentrierten Zufallsvariablen **konvergiert fast sicher** gegen 0

# Gesetze der großen Zahlen

## Schwaches und Starkes Gesetz der großen Zahlen

Unterschied Schwaches und Starkes Gesetz der großen Zahlen:

- Das starke Gesetz der großen Zahlen trifft eine Aussage über die *P-fast sichere Konvergenz* der Zufallsvariablen (konvergiert fast sicher gegen 0), das schwache Gesetz der großen Zahlen hingegen über die *stochastische Konvergenz* der Zufallsvariablen (konvergiert in Wahrscheinlichkeit gegen 0)
- Aus dem starken Gesetz der großen Zahlen folgt immer das schwache Gesetz der großen Zahlen



„Jede Statistik, egal wie primitiv, ist Magie in den Augen derer, die sie nicht verstehen“ T. Straßer


# Zentraler Grenzwertsatz (*Central Limit Theorem*)

## Satz von Moivre-Laplace


Die Verteilung der Summe einer großen Zahl von unabhängigen Zufallsvariablen folgt asymptotisch einer Normalverteilung, unabhängig von der ursprünglichen Verteilung der Zufallsvariablen



Abraham de Moivre



1718



1820




Pierre-Simon Laplace

# Zentraler Grenzwertsatz, Gesetz der großen Zahlen

- Ein Würfel


- Augenzahlen



- $E(X) = 3,5$
    - Varianz: 3,5
    - SD:  $\approx 1,87$


- Zwei Würfel

- Summe Augenzahlen



- Mittelwert: 7
    - Varianz: 6
    - SD:  $\approx 2,45$


- Mittelwert Augenzahlen



- Mittelwert:  $3,5$
    - Varianz: 1,5
    - SD:  $1,22$


- Drei Würfel

- Summe Augenzahlen



- Mittelwert: 10,5
    - Varianz:  $\approx 8,79$
    - SD:  $\approx 2,96$


- Mittelwert Augenzahlen



- Mittelwert:  $3,5$
    - Varianz:  $\approx 0,98$
    - SD:  $\approx 0,99$


- Vier Würfel

- Summe Augenzahlen



- Mittelwert: 14
    - Varianz: 11,68
    - SD:  $\approx 3,42$

- Mittelwert Augenzahlen



- Mittelwert:  $3,5$
    - Varianz:  $\approx 0,73$
    - SD:  $\approx 0,85$

- $$n \rightarrow \infty \Rightarrow \bar{X} \rightarrow E(X), \text{Var}(X) \rightarrow 0$$




The background of the slide is a close-up photograph of a document. The word 'Statistik' is printed in a bold, black, sans-serif font and is highlighted with a thick, orange, brush-stroke-like underline. Other words like 'Rolle.', 'Schaus', 'die,', and 'Merkmale' are visible in the background, slightly out of focus.

# **Statistik**

Warum die Normalverteilung gar nicht so „normal“ ist und die Log-Normalverteilung oft viel „normaler“

# Normalverteilung vs. Logarithmische Normalverteilung



| Quantile |         |       |
|----------|---------|-------|
| 100.0%   | Maximum | 176,2 |
| 99.5%    |         | 126,3 |
| 97.5%    |         | 114,1 |
| 90.0%    |         | 101,1 |
| 75.0%    | Quartil | 90    |
| 50.0%    | Median  | 78,3  |
| 25.0%    | Quartil | 67    |
| 10.0%    |         | 57,7  |
| 2.5%     |         | 48,4  |
| 0.5%     |         | 42,5  |
| 0.0%     | Minimum | 27,8  |

| Statistische Kenngrößen |           |
|-------------------------|-----------|
| Mittelwert              | 79,004467 |
| Std.-Abw.               | 16,825147 |
| Std.-Fehler Mittelwert  | 0,0561697 |
| 95% KI oben Mittelwert  | 79,114559 |
| 95% KI unten Mittelwert | 78,894375 |
| N                       | 89725     |
| Varianz                 | 283,08558 |
| Schiefe                 | 0,2962672 |
| Anzahl fehlender Werte  | 0         |

- Verteilung Gewicht in Deutschland
  - 20-75 Jahre
- Annahme: Verteilung Gewicht folgt Normalverteilung
  - $\text{Gewicht} \sim N(79,0; 283,1)$
- Aber: Schiefe  $> 0 \Rightarrow$  rechtsschief
  - Gewicht  $< 27,8$  kg  $\Rightarrow$  Tot!
    - $P(X < 27,8) = 0,0012$
  - Gewicht  $\gg 176,2$  kg  $\Rightarrow$  Ungesund, aber möglich

- Verteilung Gewicht folgt Log-Normalverteilung
  - $\text{Gewicht} \sim LN(79,0; 283,1)$
- Berechnung durch Transformation und Rücktransformation
  - Gewicht  $< 27,8$  kg  $\Rightarrow$  Tot!
    - $P(X < 27,8) \leq 0,0001$

kg

## Normalverteilung vs. Logarithmische Normalverteilung

- > Normalverteilung
  - Entsteht, wenn eine Zufallszahl durch **additive** Effekte zustande kommt
  
- > Log-Normalverteilung
  - Entsteht, wenn eine Zufallszahl durch **multiplikative** Effekte zustande kommt
  - Viele natürliche/technische Prozesse sind multiplikativ
    - z. B.: Wachstum, Verzinsung, Größenverteilungen
  - Viele natürliche/technische Prozesse sind nicht-negativ
    - Log-Normalverteilung immer  $> 0$
  - Viele natürliche/technische Prozesse sind schief
    - Log-Normalverteilung ist rechtsschief  $\rightarrow$  realistische Darstellung von Extremwerten
  
- > Wenn eine Zufallszahl aus vielen kleinen Faktoren besteht, die prozentual wirken (also multiplikativ), dann tritt Log-Normalverteilung fast automatisch auf



# Statistik

## Logarithmierte Normalverteilung

# Logarithmierte Normalverteilung



- > Stetige Wahrscheinlichkeitsverteilung
- > Verteilung einer Zufallsvariablen  $X$ , falls deren log-transformierte  $Y = \ln(X)$  normalverteilt ist
- > Modell für viele Messgrößen in Naturwissenschaften, Medizin und Technik, z. B. für Energien, Konzentrationen, Längen und Mengenangaben
- > Im Allgemeinen erfolgt statistische Analyse log-normalverteilter Größen durch 1) Logarithmieren, 2) Anwendung der Methoden der Normalverteilung und 3) Rücktransformation der Ergebnisse, z. B. Wahrscheinlichkeitsintervalle
- > Beispiel: 95% Wahrscheinlichkeitsintervall für Gewicht



95% Intervall  $Y$   
[3,9188; 4,7812]

Rücktransformation  
 $X = e^X$



95% Intervall  
[50,34; 119,25]

# Logarithmierte Normalverteilung

> Stetige Verteilung  $X \sim LN(\mu, \sigma^2)$

> Wahrscheinlichkeitsfunktion

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} * e^{-\frac{(\ln(x)-\mu)^2}{2\sigma^2}}$$

> Verteilungsfunktion  $\Phi(X)$

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x e^{\frac{1}{2} * \left(\frac{\ln(x)-\mu}{\sigma}\right)^2} dt$$

> Erwartungswert (Mittelwert)

$$E(x) = e^{\mu + \frac{\sigma^2}{2}}$$

> Median

$$e^{\mu}$$

> Modus

$$e^{\mu - \sigma^2}$$

> Varianz

$$Var(x) = e^{2\mu + \sigma^2} * (e^{\sigma^2} - 1)$$

> Standardabweichung

$$SD(x) = \sqrt{Var(x)} = e^{\mu + \frac{\sigma^2}{2}} * \sqrt{e^{\sigma^2} - 1}$$

> Variationskoeffizient

$$VarK(X) = \sqrt{e^{\sigma^2} - 1}$$

> Schiefe

$$\gamma_m = (e^{\sigma^2} + 2) * \sqrt{e^{\sigma^2} - 1}$$





# Statistik

Wie normal ist eine Verteilung? Der QQ-Plot (Wiederholung)

# Quantil-Quantil-Diagramm (Q-Q-Plot)



## Visueller Test auf Normalverteilung



- > Exploratives, grafisches Werkzeug
  - Vergleich von Verteilungen durch Auftrag der Quantilen zweier statistischer Variablen in Diagramm
  - **Vergleich empirischer Häufigkeitsverteilung mit theoretischer Verteilung (z. B. Normalverteilung)**
    - Visuelle Prüfung von Verteilungsvoraussetzungen
- > Vorgehen
  - Bestimmung empirische Quantilen  $x_i$
  - Bestimmung theoretischer Quantilen  $y_i$  für Normalverteilung
    - $p_i = F_{\text{empirisch}}(x_i)$
    - $y_i = F_{\text{theoretisch}}^{-1}(p_i)$
  - Darstellung als Wertepaare (x/y) im Diagramm
  - Wenn Merkmalswerte der theoretischen Verteilung folgen, stimmen empirische und theoretischen Quantile annähernd überein, die Punkte liegen auf der Winkelhalbierenden

# Quantil-Quantil-Diagramm (Q-Q-Plot)

## Visueller Test auf Normalverteilung



# Statistik

## Stichproben und Stichprobenfehler

## Stichprobenfehler (*sampling error*)



- > Differenz zwischen Stichprobenkennwert und Populationsparameter
  - > z. B. Stichprobenmittelwert und Mittelwert der Grundgesamtheit
  - > Ursache: Ungünstige Stichprobe, Messfehler/-abweichungen, ...
- > Beispiel
  - Zufällige Auswahl von 100 Personen aus NAKO Datensatz
  - Bestimmung Stichprobenmittelwert  $\bar{x}$
  - Stichprobenfehler =  $\mu - \bar{x} \approx 0$
- > Beispiel 2
  - Zufällige Auswahl von 3 Stichproben á 100 Personen
    - Stichprobenfehler 1 =  $\mu - \bar{x}_1 \approx 0$
    - Stichprobenfehler 2 =  $\mu - \bar{x}_2 \approx 0$
    - Stichprobenfehler 3 =  $\mu - \bar{x}_3 \approx 0$
- > Beispiel 3
  - Zufällige Auswahl von 100 Stichproben á 100 Personen
    - Verteilung Stichprobenfehler

# Stichprobenverteilung (*sampling distribution*)



- > Stichprobenfehler folgt Normalverteilung
  - ⇒ Zentraler Grenzwertsatz
  - ⇒ Stichprobenkennwert normalverteilt
  - z. B. Stichprobenmittelwerte normalverteilt
  - ⇒ Bestimmung Mittelwert von  $n$  Stichprobenmittelwerten

$$\bar{x} = \frac{1}{n} * \sum_{i=1}^n \bar{x}_i$$


- > Mittelwert der Stichprobenverteilung der Stichprobenmittelwerte

- Schätzfunktion für Mittelwert der Grundgesamtheit

$$\mu \simeq \bar{x}$$

- **Erwartungstreuer (unverzerrter) Schätzer (*unbiased estimator*)**

⇒ Gesetz der großen Zahlen



| Statistische Kenngrößen |           |
|-------------------------|-----------|
| Mittelwert              | 171,57605 |
| N                       | 100       |



## Stichprobenverteilung (*sampling distribution*)

- > Stichprobenverteilung eines Stichprobenkennwertes (Schätzers) durch Berechnung des Stichprobenkennwertes für jede mögliche zufällige Stichprobe der Länge  $n$  aus der Grundgesamtheit
  - u. A. Mittelwert, Varianz, ...
  - Folgt einer Normalverteilung
  
- > Konstruktion einer Stichprobenverteilung:
  1. Auswählen einer Population
  2. Erzeugen jeder möglichen Stichprobe der Länge  $n$
  3. Berechnung Stichprobenkennwert für jede Stichprobe der Länge  $n$  (z. B. Mittelwert)
  4. Histogramm aller Stichprobenkennwerte (z. B. Stichprobenmittelwerte)
  5. Berechnung Kennwert der Stichprobenverteilung (z. B. Mittelwert der Stichprobenmittelwerte)

## Stichprobenverteilung (*sampling distribution*)

- > In der Regel nicht möglich die ganze Population zu testen
  - Populationsparameter unbekannt
- > Schätzen der Populationsparameter aus Stichprobenverteilung
  - Allerdings: Ziehen jeder möglichen Stichprobe der Länge  $n$  auch nicht möglich
- > Aber, wir wissen: Stichprobenverteilung folgt Normalverteilung
  - Eigenschaften Normalverteilung bekannt
  - Stichprobenkennwerte (z. B. Mittelwert) erwartungstreu und unverzerrt
- > Wie „gut“ ist der Schätzer?
  - Wie gut repräsentiert der Stichprobenmittelwert den wahren Mittelwert der Population?



von  
nd  
al-  
tigter  
Rolle.  
Schaus  
die,  
enerscheinung  
Merkmalen


# **Statistik**

Intelligenzquotient

# Verteilung von Stichprobenmittelwerten

## Verteilung Intelligenzquotient

- > Kenngröße zur Bewertung intellektuelles Leistungsvermögen
  - Innerhalb bestimmten Bereichs
  - Im Vergleich zu Referenzgruppe
    - z. B. Alter, Bildungsgrad, ...
- > Entwickelt von
  - Alfred Binet (Psychologe 1857 – 1911)
    - Direktor erstes psychologisches Forschungslaboratorium
  - Théodore Simon (Arzt, Psychologe, 1873 – 1961)
- > „Intelligenzalter“
  - Anzahl gelöster Aufgaben
  - Entscheidung ob Förderung für Kind notwendig (Schulreife)
- > Normierung auf Alter: Intelligenzquotient (William Stern, 1912)
- > Neuanpassung alle 8 Jahre (DIN 33430)
- > Binet: *„Die Skala erlaubt, ehrlich gesagt, keine Messung der Intelligenz, da intellektuelle Fähigkeiten nicht addiert [...] werden können.“*
- > Zuverlässigkeit, Messfehler: Entscheidung Oberster Gerichtshof USA über Zurechnungsfähigkeit und Todesstrafe (2002: Atkins v. Virginia, 2014: Hall v. Florida)



# Verteilung von Stichprobenmittelwerten

## Verteilung Intelligenzquotient



### > Beispiel Intelligenzquotient

- Mittelwert  $\mu = 100$
- Standardabweichung  $\sigma = 15$
- $IQ \sim N(\mu, \sigma)$

### > Stichprobe (n = 16)

- Stichprobenmittelwert  $\bar{x} = 106,20$

### > Unterschied zu wahren Mittelwert

- Stichprobenfehler  $\varepsilon = 6,20$

IQ\_Stichprobe - JMP

Datei Bearbeiten Tabellen Zeilen Spalten DOE Analysieren Graph Extras  
Add-ins Ansicht Fenster Hilfe

IQ\_Stichprobe

| ID | IQ |
|----|----|
| 1  | 7  |
| 2  | 16 |
| 3  | 13 |
| 4  | 5  |
| 5  | 11 |
| 6  | 1  |
| 7  | 12 |
| 8  | 8  |
| 9  | 10 |
| 10 | 9  |
| 11 | 6  |
| 12 | 14 |
| 13 | 4  |
| 14 | 2  |
| 15 | 3  |
| 16 | 15 |


Spalten (2/0)

ID  
IQ

Zeilen


Alle Zeilen 16  
Ausgewählt 0  
Ausgeschlossen 0  
Ausgeblendet 0  
Beschriftet 0

Auswertungen fertig



# Verteilung von Stichprobenmittelwerten

## Verteilung Intelligenzquotient






# Verteilung von Stichprobenmittelwerten

## Verteilung Intelligenzquotient




- Intelligenzquotient
  - Wahrer Mittelwert Population  $\mu = 100$
  - Wahre Standardverteilung Population  $\sigma = 15$
- Stichprobe ( $n = 2$ )
  - 100.000 Stichproben
- Mittelwerte der Stichprobe
  - Normalverteilt
  - Mittelwert der Mittelwerte  $\approx 100$
- Standardabweichung der Mittelwerte der Stichproben  $\approx 10$


Beobachtung 1



Beobachtung 2




Mittelwert[Beob...,Beobachtung 2]



# Verteilung von Stichprobenmittelwerten

## Streuung der Stichprobenmittelwerte



$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

# Statistik

Standardfehler

## Standardfehler (*sampling error*)

- > Standardabweichung der Verteilung der Stichprobenmittelwerte
  - Standardabweichung der Stichprobenverteilung der Stichprobenmittelwerte
  - *Standard/Sampling Error (of Means)*, SEM

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \sqrt{\frac{\sigma^2}{n}}$$

- > Vergrößerung der Stichprobengröße um  $n$  verringert die Standardabweichung der Stichprobenverteilung um die Wurzel der Stichprobengröße  $n$ 
  - Gesetz der großen Zahlen
- > Beschreibt die „Nähe“ des Stichprobenmittelwerts zum wahren Mittelwert der Population
  - Mittlere Differenz des Stichprobenmittelwerts zum Mittelwert der Grundgesamtheit


# Stichprobenverteilung

## Eigenschaften

- > Mittelwert  $\bar{x} \simeq \mu$  (Mittelwert der Population)
  - Erwartungstreu
  - Unverzerrt (*unbiased*)
  
- > Standardabweichung: Standardfehler des Mittelwerts der Stichprobenmittelwerte
  - $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$
  - Vergrößerung der Stichprobengröße um  $n$  verringert die Standardabweichung der Stichprobenverteilung um die Wurzel der Stichprobengröße  $n$
  
- > Folgt Normalverteilung
  - Unter welchen Bedingungen?

# Stichprobenverteilung von nicht normalverteilten Zufallsvariablen

> Gleichverteilung





# Statistik

Take Home

# Take Home

- Statistische Klassifikation
  - Kontingenztafel, Vierfeldertafel, Konfusionsmatrix
  - Maßzahlen für statistische Klassifikation
  - Receiver Operation Characteristic (ROC)
- Schätzung bei unbekannter Verteilung
  - Ungleichung von Bienaymé-Tschebyscheff
- Log-Normalverteilung
- Grenzsätze der Stochastik
  - Schwaches & starkes Gesetz der Großen Zahlen
  - Zentraler Grenzwertsatz
- Stichproben und Stichprobenfehler
- Stichprobenverteilungen
  - Verteilung Stichprobenmittelwert
    - Standardfehler